Laporan Praktikum Kecerdasan Buatan

Text Classification



Citra M.Sidabutar

42324028

Dlll Teknologi Informasi

INSTITUT TEKNOLOGI DEL
FAKULTAS VOKASI
2026/2027

Praktikum Text Classification

1. In Cell 1

Code

```
# Import Library
import pandas as pd
import numpy as np
import re
import string
from nltk.tokenize import word_tokenize
from nltk.stem import WordNetLemmatizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
```

Penjelasan

Kode ini digunakan untuk mempersiapkan alat-alat yang diperlukan sebelum melakukan klasifikasi teks. pandas berfungsi untuk membaca dan mengorganisasi data, sedangkan numpy berguna untuk memanipulasi data dalam format numerik. Selanjutnya, re dan string diterapkan untuk membersihkan teks, seperti menghapus angka dan tanda baca yang tidak perlu. word_tokenize berperan untuk memisahkan kalimat menjadi kata-kata, sedangkan WordNetLemmatizer membantu mengonversi kata-kata ke bentuk dasarnya. Setelah teks siap untuk diproses, TfidfVectorizer digunakan untuk mengubah teks menjadi angka agar bisa diproses oleh komputer. Selanjutnya, KMeans bertugas untuk mengategorikan teks berdasarkan kesamaannya, sementara PCA membantu menyederhanakan data supaya hasil klasifikasi lebih mudah untuk ditampilkan secara grafis. Akhirnya, matplotlib. pyplot digunakan untuk membuat dan menampilkan grafik yang menunjukkan hasil klasifikasi tersebut.

2. In Cell 2

Code

```
# Load dataset
file_path = "text.csv"
df = pd.read_csv(file_path)

# Hanya mengambil kolom message untuk klasterisasi
df = df.rename(columns={'Message': 'text'})
```

Penjelasan

Kode ini berfungsi untuk mengakses dataset yang akan digunakan dalam kegiatan pengelompokan teks. Di bagian file_path = "text. csv", nama file dataset telah ditentukan, lalu pd.read_csv(file_path) digunakan untuk membaca konten file tersebut dan menyimpannya dalam variabel df. Setelah itu, df.rename(columns={'Message': 'text'}) dipakai untuk mengubah nama kolom Message menjadi text supaya lebih gampang diakses di langkah-langkah selanjutnya. Dengan cara ini, isi pesan dalam dataset dapat dimanfaatkan sebagai data utama dalam proses pembersihan teks dan pengelompokan berdasarkan kesamaannya.

3. In Cell 3

Code

```
# Inisialisasi lemmatizer
lemmatizer = WordNetLemmatizer()

# Fungsi preprocessing teks
Tabnine | Edit | Test | Explain | Document
def clean_text(text) :
    text = text.lower()     # LowerCasing
    text = re.sub(r'\d+', '', text)     # Hapus angka
    text = text.translate(str.maketrans('', '', string.punctuation))  # Hapus tanda baca
    words = word_tokenize(text)     # Tokenisasi
    words = [lemmatizer.lemmatize(word) for word in words] # Lemmatization
    return ' '.join(words)

# Terapkan preprocessing ke teks
df['clean_text'] = df['text'].apply(clean_text)

# Konversi tekske vektor TF-IDF
vectorizer = TfidfVectorizer(stop_words='english') # Menggunakan stopwords daari sklearn
X = vectorizer.fit_transform(df['clean_text'])

# Tentukan jumlah klaster
num_clusters = 2
kmeans = KMeans(n_clusters=num_clusters, random_state=42, n_init=10)
df['cluster'] = kmeans.fit_predict(X)

# Visualisasi dengan PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X.toarray())

plt.figure(figsize=(8, 6))
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=df['cluster'], cmap='viridis', alpha=0.7)
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.title("Text Clustering dengan K-Means")
plt.colorbar(label='Cluster')
plt.show()
```

Penjelasan

Kode ini berfungsi untuk membersihkan konten teks, mengkonversinya menjadi format numerik, dan kemudian mengelompokkan pesan berdasarkan tingkat kesamaan. Pertama-tama, WordNetLemmatizer() dipersiapkan untuk membantu transformasi kata menjadi bentuk dasar. Selanjutnya, fungsi clean_text() bertugas membersihkan setiap pesan dengan mengubah huruf menjadi kecil, menghapus angka serta tanda baca, memecah kalimat menjadi kata, serta melakukan proses lemmatization. Hasil dari pembersihan ini disimpan dalam kolom baru yang dinamakan clean_text. Setelah itu,

TfidfVectorizer(stop_words='english') digunakan untuk mengonversi teks menjadi angka sambil mengabaikan kata-kata umum dalam bahasa Inggris yang dianggap tidak memberikan informasi yang berarti. Kemudian, KMeans diterapkan untuk mengelompokkan pesan menjadi dua kategori berdasarkan kesamaan teks, di mana hasil kelompok tersebut disimpan dalam kolom cluster. Dalam bagian visualisasi, PCA(n_components=2) menyederhanakan data menjadi dua komponen agar bisa direpresentasikan dalam bentuk grafik. Fungsi plt.scatter() selanjutnya menggambarkan setiap pesan sebagai titik dengan warna yang berbeda sesuai dengan kelompoknya, sementara plt.xlabel(), plt.ylabel(), dan plt.title() menyediakan keterangan pada grafik. Akhirnya, plt.colorbar() menyajikan penanda warna untuk setiap kelompok dan plt.show() memperlihatkan hasil visualisasi.

Output

